PROJETO DNN_STUDY · UFRGS

Protocolo experimental e suas justificativas

Phases 11–13: cada parâmetro, o porquê e a referência

26 de outubro de 2026

Como ler este documento

Princípio. Uma única receita para todas as redes, com cada número vindo de uma referência: comparar arquiteturas exige um setup fixo (Radosavovic et al., 2019). Um valor que nenhuma referência fixa está na seção 6, marcado *em laranja* nas tabelas.
Onde estão os valores. Quem manda é `configs/experiments/_protocols/no_patience.yaml`. Todo `phase_11_*.yaml` herda dele; cada `phase_12_*` declara uma diferença, e os `phase_13_*` usam a receita exata. `tests/test_config.py` falha se algum yaml se desviar. Este documento explica os valores, não os define.
Histórico das decisões. `docs/logs/PHASE11_LOG.md`, nas seções "Literature-standard INT8 + held-out test set" e "One recipe, every number from a reference" (03/10/2026) e "Protocol audit" (07/10/2026).

1 Treino FP32

Escolha	Valor	Justificativa	Referência
Otimizador	SGD, momentum 0,9, weight decay (L2) 5e-4	A receita do AlexNet; o VGG usa os mesmos valores.	Krizhevsky et al. 2012, Sec. 5; Simonyan & Zisserman 2015, Sec. 3.1
lr e batch	0,01; batch 128; igual em toda rede	Os valores do AlexNet (o VGG usa 0,01 com batch 256).	Krizhevsky et al. 2012
Schedule	cosine até 0, sem warmup	Um dos dois refinamentos de treino que valem em ResNet, Inception e MobileNet. Warmup serve para lr escalado com batch grande, o que não é o caso aqui.	He, T. et al. 2019, Sec. 5; Goyal et al. 2017
Loss	cross-entropy com label smoothing 0,1	O outro refinamento do mesmo trabalho.	He, T. et al. 2019, Sec. 5; Szegedy et al. 2016
Orçamento	500 épocas fixas, sem early stopping	Com o lr indo a zero no fim, um orçamento maior agiria num platô. A convergência é verificada run a run (`convergence()`).	Li, Yumer & Ramanan 2020; *o valor 500: escolha própria*
Inicialização	He (normal, fan_out) nas convs; N(0; 0,01) nas Linear	Com a std fixa do AlexNet nas convs, a escala do sinal cresce com $\sqrt{\text{fan-in}}$, isto é, com o tamanho do kernel, que é a variável do estudo. He normaliza pelo fan.	He et al. 2015, Eq. 10; Krizhevsky et al. 2012 (Linear)
Precisão	treino em precisão mista, avaliação em FP32	O padrão de treino misto.	Micikevicius et al. 2018
Cabeça FC	com Dropout 0,5	A cabeça original do AlexNet e da VGG. A FC sem Dropout, que nenhuma referência usa, memorizou o treino (99,9% treino / 38,5% validação) e só aparece como o contraste do Dropout.	Krizhevsky et al. 2012, Sec. 4.2; Simonyan & Zisserman 2015

2 Dados e avaliação

Escolha	Valor	Justificativa	Referência
Dataset	Tiny ImageNet, 64×64, 200 classes	Velocidade. Conclusões de hiperparâmetros passam do ImageNet reduzido ao completo.	Chrabaszcz et al. 2017
Augmentation	deslocamento de até 4 px (pad 4 + crop) + flip horizontal; depois AutoAugment (política ImageNet)	O ImageNet 64×64 usa exatamente esses deslocamentos. Equivale à faixa de crop do AlexNet relativa à imagem (32/256 = 8/64).	Chrabaszcz et al. 2017, Sec. 3; Cubuk et al. 2019

Escolha	Valor	Justificativa	Referência
Escolha da época	split 90/10 do train	O hold-out de treino padrão (45k/5k no CIFAR).	He et al. 2016, Sec. 4.2
Número reportado	top-1 no val oficial do Tiny ImageNet (10 mil imagens), usado como test set	Quem escolhe o modelo não pode ser quem o mede. O test set é o mesmo para todo seed; o split 90/10 muda com o seed.	Cawley & Talbot 2010
Calibração	ECE com 15 bins	A medida padrão.	Guo et al. 2017

3 QAT e INT8

Escolha	Valor	Justificativa	Referência
Duração e lr do QAT	50 épocas (1/10 do FP32); lr 1e-4 (1/100 do FP32), cosine até 1e-6; mesmo SGD	A regra de fine-tuning do QAT: só o lr e o schedule mudam.	Wu et al. 2020, App. A.2
BatchNorm no QAT	intacto, nunca congelado	O BN fica fora da quantização no treino e entra na escala de cada canal depois, "igual ou melhor" que dobrar estático. Congelar o BN com lr 1e-4 custou ∼1,5 pp (medido).	Wu et al. 2020; Nagel et al. 2021, Sec. 4.2, Tab. 7
Faixa das ativações	observers EMA durante todo o QAT	A definição do QAT.	Jacob et al. 2018, Sec. 3.1
Ativações	8 bits, per-tensor, afim	A definição de INT8 da literatura; afim não custa nada a mais que simétrica.	Jacob et al. 2018; Wu et al. 2020, Sec. 3.3
Pesos	8 bits, per-channel, simétricos em $[-127, 127]$	A mesma definição; spec int8 do LiteRT.	Wu et al. 2020, Sec. 6
O que é quantizado	entrada e pesos de toda Conv/Linear; logits em FP32; ativação fundida à camada que a produz	"Uma operação é quantizada quantizando suas entradas." A saída dos logits não alimenta nenhuma camada quantizada.	Wu et al. 2020, Sec. 4; Jacob et al. 2018
Motor da acurácia INT8	qnnpack (soma exata em int32)	onednn e fbgemm saturam pares u8×s8 em int16 em CPUs sem VNNI (beagle, tupi1/2), o que custou 1–5 pp. A acurácia não pode depender da máquina.	oneDNN dev guide; PyTorch issue #103646
Motor da latência INT8	onednn	Só para medir tempo.	—

4 Desenho experimental e análise

Escolha	Valor	Justificativa	Referência
Padding do kernel 2×2	simétrico (C2sp)	Padding de um lado só desloca o mapa 0,5 px por camada. O C2sp ganha 2,5% sobre ele no ImageNet, a ordem do efeito de kernel medido aqui (1–3 pp): o padding antigo inflaria o custo do 2×2.	Wu, S. et al. 2019, Sec. 3–6
Stem profundo da ResNet	três convs pequenas no lugar da conv1	O stem de kernel pequeno da literatura (ResNet-C).	He, T. et al. 2019, Sec. 4.2
Redes pré-treinadas	cada uma com uma gêmea do zero	O pré-treino é a única variável do contraste.	desenho do fatorial
Ruído entre seeds	seeds 42/43/44 em células-chave de cada regime; faixa $2\sqrt{2}\cdot$SD	A diferença de duas runs tem SD $\sqrt{2}\cdot$SD, e ± 2 SD ≈ 95%. Um contraste de uma seed dentro da faixa é "sem evidência de diferença", nunca um ranking.	Bouthillier et al. 2021
Efeito de cada fator	pares iguais em tudo menos no fator; mediana com IC 95% por bootstrap	A réplica que um fatorial sem repetição tem.	Efron & Tibshirani 1993

Escolha	Valor	Justificativa	Referência
Ranking dos kernels	Friedman + Nemenyi, com e sem BN separados	Comparação de vários tratamentos em vários blocos.	Demšar 2006
Testes pareados	McNemar exato entre duas redes nas mesmas imagens; Holm na tabela; IC de Wilson	Testes pareados e correção para múltiplas comparações.	Dietterich 1998; Holm 1979; Wilson 1927
Respostas trocadas	imagens que mudam de certo para errado entre FP32 e INT8	A mesma acurácia pode esconder respostas diferentes.	Hooker et al. 2019
Campo receptivo efetivo	gradiente do neurônio central em 200 imagens de teste	A medida padrão.	Luo et al. 2016
Latência	`torch.utils.benchmark`: mediana + IQR, um lote já no dispositivo, threads fixas	Só se compara dentro da mesma máquina.	PyTorch benchmark utilities
Reprodutibilidade	seeds fixas, `cudnn.deterministic`, TF32 desligado, dependências fixas; git, CUDA, GPU e hash do dataset na proveniência	O que os checklists de reprodutibilidade pedem.	Pineau et al. 2021

5 Phase 12: a mesma receita com uma mudança declarada

Experimento	Valor	Justificativa	Referência
`lr_half` / `lr_double`	lr do FP32: 0,005 / 0,02	Uma oitava para cada lado de 0,01: o ranking dos kernels depende do lr?	*escolha própria*
`finetune_*`	pré-treinadas com fine-tuning de verdade: 100 épocas, lr 1e-3 e 1e-4; QAT de 10 épocas a 1/100 do lr	O melhor lr de fine-tuning depende do dataset alvo, então nenhum lr único é afirmado. Cada rede é lida no lr com melhor top-1 na *validação*. O QAT segue a regra da seção 3.	Li, H. et al. 2020 (grade da App. D); Wu et al. 2020, App. A.2
`cifar100` **(+ seeds)**	CIFAR-100 32×32 no lugar do Tiny ImageNet; mesmas redes, receita e augmentation	Só o dado muda; trocar a política do AutoAugment seria uma segunda mudança. Hold-out 45k/5k.	He et al. 2016, Sec. 4.2
`kernel_controls` **(Phase 11)**	larguras ×1,5 (2×2) e ×0,67 (3×3)	Iguala os MACs do outro kernel (dentro de 2%, testado): separa o kernel da capacidade.	cálculo a partir das formas das camadas

6 Escolhas próprias e limitações declaradas

Escolhas sem referência que as fixe, todas constantes do protocolo e iguais para toda run:

- **500 épocas.** Nenhum trabalho no Tiny ImageNet prescreve um orçamento. São 352 mil iterações: entre os schedules longos do CIFAR (78k–234k) e os do ImageNet (AlexNet ∼844k), numa faixa de retorno decrescente (Wightman et al., 2021). A convergência é checada run a run.
- **4 workers no DataLoader.** Mudar o número mudaria o fluxo aleatório da augmentation das runs já treinadas.
- **Marca de "melhor época cedo"** (`EARLY_FRAC` = **0,8**)**.** Uma run cuja melhor época FP32 cai antes de 80% do orçamento tem o INT8 marcado nas figuras. Nesse caso o QAT parte de um checkpoint ainda não recozido, e o ganho FP32 → INT8 é treino extra, não quantização. O limiar separa os dois grupos observados (melhor época em 56–197 ou em 396–499).
- **Guarda** `MIN_QAT_INT8_AGREEMENT` = **0,90.** Verifica que o código está certo; não é métrica reportada.
- **lr ×0,5 e ×2 na Phase 12.**

Limitações:

- **Receita única.** Não é a receita própria da MobileNetV2 (wd 4e-5) nem da ResNet (lr 0,1, wd 1e-4), e uma receita pode reordenar arquiteturas (Bello et al., 2021; Wightman et al., 2021). A Phase 12 testa a robustez a isso.
- **Pré-treino com a receita única.** Com lr 0,01 por 500 épocas, o pré-treino é quase todo apagado, e as redes pré-treinadas atingem a melhor época cedo. O fine-tuning de verdade está na Phase 12.
- **Datasets.** Tiny ImageNet e, na Phase 12, CIFAR-100.

Referências

- Bello, I. et al. Revisiting ResNets: Improved Training and Scaling Strategies. *NeurIPS*, 2021.
- Bouthillier, X. et al. Accounting for Variance in Machine Learning Benchmarks. *MLSys*, 2021.
- Cawley, G. & Talbot, N. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. *JMLR*, 2010.
- Chrabaszcz, P., Loshchilov, I. & Hutter, F. A Downsampled Variant of ImageNet as an Alternative to the CIFAR datasets. 2017.
- Cubuk, E. et al. AutoAugment: Learning Augmentation Strategies from Data. *CVPR*, 2019.
- Demšar, J. Statistical Comparisons of Classifiers over Multiple Data Sets. *JMLR*, 2006.
- Dietterich, T. Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms. *Neural Computation*, 1998.
- Efron, B. & Tibshirani, R. *An Introduction to the Bootstrap*. 1993.
- Goyal, P. et al. Accurate, Large Minibatch SGD: Training ImageNet in 1 Hour. 2017.
- Guo, C. et al. On Calibration of Modern Neural Networks. *ICML*, 2017.
- He, K. et al. Delving Deep into Rectifiers. *ICCV*, 2015.
- He, K. et al. Deep Residual Learning for Image Recognition. *CVPR*, 2016.
- He, T. et al. Bag of Tricks for Image Classification with Convolutional Neural Networks. *CVPR*, 2019.
- Holm, S. A Simple Sequentially Rejective Multiple Test Procedure. *Scandinavian Journal of Statistics*, 1979.
- Hooker, S. et al. What Do Compressed Deep Neural Networks Forget? 2019.
- Jacob, B. et al. Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference. *CVPR*, 2018.
- Krizhevsky, A., Sutskever, I. & Hinton, G. ImageNet Classification with Deep Convolutional Neural Networks. *NeurIPS*, 2012.
- Li, H. et al. Rethinking the Hyperparameters for Fine-tuning. *ICLR*, 2020.
- Li, M., Yumer, E. & Ramanan, D. Budgeted Training: Rethinking Deep Neural Network Training Under Resource Constraints. *ICLR*, 2020.
- Luo, W. et al. Understanding the Effective Receptive Field in Deep Convolutional Neural Networks. *NeurIPS*, 2016.
- Micikevicius, P. et al. Mixed Precision Training. *ICLR*, 2018.
- Nagel, M. et al. A White Paper on Neural Network Quantization. 2021.
- Pineau, J. et al. Improving Reproducibility in Machine Learning Research. *JMLR*, 2021.
- Radosavovic, I. et al. On Network Design Spaces for Visual Recognition. *ICCV*, 2019.
- Simonyan, K. & Zisserman, A. Very Deep Convolutional Networks for Large-Scale Image Recognition. *ICLR*, 2015.
- Szegedy, C. et al. Rethinking the Inception Architecture for Computer Vision. *CVPR*, 2016.
- Wightman, R., Touvron, H. & Jégou, H. ResNet Strikes Back: An Improved Training Procedure in timm. 2021.
- Wilson, E. Probable Inference, the Law of Succession, and Statistical Inference. *JASA*, 1927.
- Wu, H. et al. Integer Quantization for Deep Learning Inference: Principles and Empirical Evaluation. 2020.
- Wu, S. et al. Convolution with Even-Sized Kernels and Symmetric Padding. *NeurIPS*, 2019.