

Restrição do Tamanho de Kernel em CNNs e Sua Eficiência

Rafael Silva de Souza

Experimentos

- **Dataset:** Tiny ImageNet-200 (64×64 RGB, 200 classes) [1]
- **Pipeline:** Treinamento FP32 → ajuste fino QAT [2] → inferência INT8 via fbgemm [3], em PyTorch [4]
- **Escopo:** 4 fases, mais de 25 variantes de arquitetura

Motivação: Por Que o Tamanho do Kernel Importa


O problema: A convolução acelerada por Winograd [5] atinge alta eficiência para kernels pequenos (2×2 , 3×3), mas escala mal para filtros grandes.

Pergunta: É possível trocar tamanho de kernel por eficiência em aceleradores Winograd sem sacrificar a acurácia? Quão robusta é essa troca sob quantização?


Design da Pesquisa

Fase	Foco	Modelos-Chave
1	Baselines pré-treinados	MobileNetV2 [6], ResNet18 [7], VGGStyle [8], AlexNet [9]
2	Restrição de kernel	AlexNet 3×3, 2×2, SmallKernel (otimizado)
3	Mecanismos de compensação	Bottleneck [7], Fire [10], Residual [7], DepthwiseSep [11]
4	Arquiteturas híbridas finais	Fire-Residual, Bottleneck-Fire (FP32 + compressão extrema)

A Restrição de Kernel



Equivalentes em INT8




ResNet18 omitido — não existe resultado INT8/QAT para esse baseline pré-treinado.


Comparação

	SmallKernel	Residual
Mecanismo	Canais mais estreitos (64 → 128 → 256 → 256 → 256) + cabeça GAP no lugar das FC 4096+4096 + camadas 3×3 para compensar o campo receptivo	5 blocos residuais [7]: duas conv 3×3+BN+ReLU somadas ao atalho via FloatFunctional ; canais e cabeça FC iguais ao AlexNet3x3
Parâmetros	1,6M	57,8M
Tamanho	18 MB	694 MB
FP32 → INT8	45,8% → 35,9%	48,0% → 47,3%

Comparaç o FP32 vs. INT8



Melhores Modelos (até o momento)



Compressão Extrema



Referências

- [1] LE, Y.; YANG, X. *Tiny ImageNet visual recognition challenge*. Stanford: CS231N Course Technical Report, 2015.
- [2] JACOB, B. et al. *Quantization and training of neural networks for efficient integer-arithmetic-only inference*. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2018, Salt Lake City. Proceedings [...]. Piscataway: IEEE, 2018. p. 2704-2713.
- [3] KHUDIA, D. et al. *FBGEMM: enabling high-performance low-precision deep learning inference*. arXiv preprint arXiv:2101.05615, 2021.
- [4] PASZKE, A. et al. *PyTorch: an imperative style, high-performance deep learning library*. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 32., 2019, Vancouver. Proceedings [...]. 2019. p. 8024-8035.

Referências (cont.)

[5] LAVIN, A.; GRAY, S. *Fast algorithms for convolutional neural networks*. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2016, Las Vegas. Proceedings [...]. Piscataway: IEEE, 2016. p. 4013-4021.

[6] SANDLER, M.; HOWARD, A.; ZHU, M.; ZHMOGINOV, A.; CHEN, L. *MobileNetV2: inverted residuals and linear bottlenecks*. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2018, Salt Lake City. Proceedings [...]. Piscataway: IEEE, 2018. p. 4510-4520.

[7] HE, K.; ZHANG, X.; REN, S.; SUN, J. *Deep residual learning for image recognition*. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2016, Las Vegas. Proceedings [...]. Piscataway: IEEE, 2016. p. 770-778.

[8] SIMONYAN, K.; ZISSERMAN, A. *Very deep convolutional networks for large-scale image recognition*. In: INTERNATIONAL CONFERENCE ON LEARNING

Referências (cont.)

[9] KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. *ImageNet classification with deep convolutional neural networks*. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 25., 2012. Proceedings [...]. p. 1097-1105.

[10] IANDOLA, F. N. et al. *SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size*. arXiv preprint arXiv:1602.07360, 2016.

[11] HOWARD, A. G. et al. *MobileNets: efficient convolutional neural networks for mobile vision applications*. arXiv preprint arXiv:1704.04861, 2017.

Obrigado