

Restrição do Tamanho de Kernel em CNNs e Sua Eficiência

Rafael Silva de Souza

Experimentos

- **Dataset:** Tiny ImageNet-200 (64×64 RGB, 200 classes)
- **Pipeline:** Treinamento FP32 → ajuste fino QAT → inferência INT8
- **Escopo:** 4 fases, mais de 25 variantes de arquitetura

Motivação: Por Que o Tamanho do Kernel Importa


O problema: A convolução acelerada por Winograd atinge alta eficiência para kernels pequenos (2×2 , 3×3), mas escala mal para filtros grandes.

Nossa pergunta: É possível trocar tamanho de kernel por eficiência em aceleradores Winograd sem sacrificar a acurácia? Quão robusta é essa troca sob quantização?


Design da Pesquisa

Fase	Foco	Modelos-Chave
1	Baselines pré-treinados	MobileNetV2, ResNet18, VGGStyle, AlexNet
2	Restrição de kernel	AlexNet 3×3, 2×2, SmallKernel (otimizado)
3	Mecanismos de compensação	Bottleneck, Fire, Residual, DepthwiseSep
4	Arquiteturas híbridas finais	Fire-Residual, Bottleneck-Fire (FP32 + compressão extrema)

A Restrição de Kernel



Equivalentes em INT8




ResNet18 omitido — não existe resultado INT8/QAT para esse baseline pré-treinado.


Dois Caminhos de Recuperação

	 SmallKernel	 Residual
Mecanismo	Canais mais estreitos (64 → 128 → 256 → 256 → 256) + cabeça GAP no lugar das FC 4096+4096 + camadas 3×3 para compensar o campo receptivo	5 blocos residuais: duas conv 3×3+BN+ReLU somadas ao atalho via FloatFunctional ; canais e cabeça FC iguais ao AlexNet3x3
Parâmetros	1,6M	57,8M
Tamanho	18 MB	694 MB
FP32 → INT8	45,8% → 35,9%	48,0% → 47,3%

Descoberta 2: Mecanismos de Compensação Recuperam Acurácia



O Vencedor Híbrido: Arquitetura Fire-Residual



O Vencedor Híbrido (continuação)

Melhor modelo compacto (<10 MB):

- **alexnet_final_fire_residual**: 49,8% FP32 → 49,2% INT8 @ **8,09 MB**
- Iguala a acurácia do MobileNetV2 (57,9%) com **~3,5× menos tamanho**
- Robusto à quantização (queda de -0,6pp)

Por que essa arquitetura vence:

- Módulo Fire: reaproveitamento de features eficiente em parâmetros
- Conexões residuais: fluxo de gradiente + estabilidade na quantização
- Kernels pequenos: compatíveis com aceleradores Winograd

Compressão Extrema: Levando os Limites Adiante



Compressão Extrema (continuação): Trade-offs de Design

Quão pequeno podemos ir? A quantização extrema viabiliza modelos ultracompactos:

- **QAT Ternário:** 35–44% de acurácia @ 0,1–0,5 MB
- **QAT Int4:** 41–45% de acurácia @ 1–2 MB
- **Precisão mista:** ponto ideal em 5–8 MB

Decisão de design: modelos abaixo de 1 MB existem, mas a acurácia cai bruscamente abaixo de 30%. O ponto de inflexão: **5–8 MB é a faixa prática** para >40% de acurácia no Tiny ImageNet-200.

Conclusões e Recomendações

Seleção de modelo por caso de uso:

- **Produção (>45% de acurácia):** arquiteturas Fire, Bottleneck ou Fire-Residual
- **Edge (<10MB):** híbrido Fire-Residual (49,2% INT8)
- **Ultracompacto (<1MB):** quantização Ternária/Int4 (30–40% de acurácia)

Descoberta-chave: CNNs compatíveis com Winograd entregam **4,3× melhor acurácia por MB** do que designs convencionais, sem sacrificar a robustez à quantização.

Referências e Trabalhos Relacionados

- **Convolução Rápida de Winograd:** Lavin & Gray (2016), *"Fast Algorithms for Convolutional Neural Networks"*
- **Treinamento com Quantização (QAT):** Jacob et al. (2018), framework de QAT do PyTorch
- **CNNs Eficientes:** Sandler et al. (2018, MobileNetV2), He et al. (2016, ResNet), Iandola et al. (2016, SqueezeNet)
- **Inferência INT8:** backend fbgemm da Intel; documentação de quantização do PyTorch
- **Dataset:** desafio Tiny ImageNet-200 (classificação 64×64)

Obrigado