

Restrição do Tamanho de Kernel em CNNs e Sua Eficiência

Rafael Silva de Souza

Experimentos

- **Dataset:** Tiny ImageNet-200 (64×64 RGB, 200 classes) [1]
- **Pipeline:** Treinamento FP32 → ajuste fino QAT [2] → inferência INT8 via fbgemm [3], em PyTorch [4]
- **Escopo:** 4 fases, mais de 25 variantes de arquitetura

Motivação: Por Que o Tamanho do Kernel Importa


O problema: A convolução acelerada por Winograd [5] atinge alta eficiência para kernels pequenos (2×2 , 3×3), mas escala mal para filtros grandes.

Pergunta: É possível trocar tamanho de kernel por eficiência em aceleradores Winograd sem sacrificar a acurácia? Quão robusta é essa troca sob quantização?

Design da Pesquisa


Fase	Foco	Modelos-Chave
1	Baselines pré-treinados	MobileNetV2 [6], ResNet18 [7], VGGStyle [8], AlexNet [9]
2	Restrição de kernel	AlexNet 3×3, 2×2, SmallKernel (otimizado)
3	Mecanismos de compensação	Bottleneck [7], Fire [10], Residual [7], DepthwiseSep [11]
4	Arquiteturas híbridas finais	Fire-Residual, Bottleneck-Fire (FP32 + compressão extrema)

Restrição de Kernel



Modelo	Head	Camadas FC
MobileNetV2, VGG-Style, ResNet18, 2x2, Mixed, SmallKernel, Fire-Residual	GAP (1x1)	1
AlexNet 3x3, Residual	AvgPool (6x6)	3

Equivalentes em INT8




ResNet18 e MobileNetV2 omitidos — sem resultado INT8/QAT válido para esses baselines pré-treinados (somas residuais nativas, incompatíveis com conversão INT8).


Comparação

	SmallKernel	Residual	Fire-Residual
Mecanismo	Canais estreitos + GAP + 3×3	Blocos residuais [7] (FloatFunctional)	Fire [10] + atalho residual
Parâmetros	1,6M	57,8M	0,7M
Tamanho	18 MB	694 MB	8 MB
FP32 → INT8	45,8% → 35,9%	48,0% → 47,3%	49,8% → 49,2%


Comparaç o FP32 vs. INT8



Melhores Modelos (até o momento)



Compressão Extrema



Referências

- [1] LE, Y.; YANG, X. *Tiny ImageNet visual recognition challenge*. Stanford: Stanford University, 2015. (CS231N Course Technical Report).
- [2] JACOB, B. *et al.* Quantization and training of neural networks for efficient integer-arithmetic-only inference. In: IEEE CVPR, 2018, Salt Lake City. *Anais [...]*. Piscataway: IEEE, 2018. p. 2704-2713.
- [3] KHUDIA, D. *et al.* *FBGEMM: enabling high-performance low-precision deep learning inference*. [S. l.]: arXiv, 2021. arXiv:2101.05615.
- [4] PASZKE, A. *et al.* PyTorch: an imperative style, high-performance deep learning library. In: NeurIPS, 32., 2019, Vancouver. *Anais [...]*. [S. l.]: Curran Associates, 2019. p. 8024-8035.
- [5] LAVIN, A.; GRAY, S. Fast algorithms for convolutional neural networks. In: IEEE CVPR, 2016, Las Vegas. *Anais [...]*. Piscataway: IEEE, 2016. p. 4013-4021.
- [6] SANDLER, M. *et al.* MobileNetV2: inverted residuals and linear bottlenecks. In: IEEE CVPR, 2018, Salt Lake City. *Anais [...]*. Piscataway: IEEE, 2018. p. 4510-4520.
- [7] HE, K. *et al.* Deep residual learning for image recognition. In: IEEE CVPR, 2016, Las Vegas. *Anais [...]*. Piscataway: IEEE, 2016. p. 770-778.
- [8] SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. In: ICLR, 3., 2015, San Diego. *Anais [...]*. [S. l.: s. n.], 2015.
- [9] KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. ImageNet classification with deep convolutional neural networks. In: NeurIPS, 25., 2012, Lake Tahoe. *Anais [...]*. [S. l.]: Curran Associates, 2012. p. 1097-1105.
- [10] IANDOLA, F. N. *et al.* *SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size*. [S. l.]: arXiv, 2016. arXiv:1602.07360.
- [11] HOWARD, A. G. *et al.* *MobileNets: efficient convolutional neural networks for mobile vision applications*. [S. l.]: arXiv, 2017. arXiv:1704.04861.

Obrigado