

Restrição do Tamanho de Kernel em CNNs para Aceleração Winograd

Rafael Silva de Souza
Curso de Engenharia de Computação

Instituto de Informática
Universidade Federal do Rio Grande do Sul (UFRGS)
rafael.souza@inf.ufrgs.br

Mateus Grellert da Silva
Professor Adjunto, Orientador

Instituto de Informática
Universidade Federal do Rio Grande do Sul (UFRGS)
mateus.grellert@inf.ufrgs.br

Abstract—Aceleradores baseados no algoritmo de Winograd oferecem ganhos expressivos de eficiência para convoluções de kernel pequeno (2×2 , 3×3) [2], mas escalam mal para kernels grandes (5×5 , 11×11), comuns em arquiteturas clássicas como a AlexNet. Este trabalho investiga o custo de restringir o tamanho de kernel de uma CNN e se esse custo pode ser recuperado sem reintroduzir kernels grandes. Treinamos variantes da AlexNet no Tiny ImageNet-200 (64×64 , 200 classes) sob um pipeline FP32 $\rightarrow$ Quantization-Aware Training (QAT) $\rightarrow$ INT8, comparando um baseline de kernel irrestrito, uma restrição ingênua a 3×3 e uma família de mecanismos de compensação estrutural leve — blocos *bottleneck* ($1\times 1 \rightarrow 3\times 3 \rightarrow 1\times 1$), módulos *Fire* [4] e um atalho residual isolado — todos mantendo os kernels $\leq 3\times 3$. A variante com *bottleneck* (AlexNetBottleneck) atinge 44,62% de acurácia top-1 em FP32 com apenas 0,385M parâmetros (4,49 MB) — superando a restrição ingênua em mais de 4 pontos percentuais com 6 $\times$ menos parâmetros — e apresenta a menor queda de acurácia sob quantização INT8 do estudo (-0,08 p.p.). Uma ablação subsequente isola o efeito de um único atalho residual adicionado a um bloco *Fire*, sem nenhum parâmetro extra (AlexNetFireBypass): esse atalho captura aproximadamente 87% do ganho de acurácia FP32 obtido por uma arquitetura híbrida bem mais complexa que combina *stem* e *Fire+residual*, e supera essa arquitetura no regime INT8 (49,86% vs. 49,20%); nota-se que o AlexNetFireBypass usou orçamento de épocas superior. Medições diretas de hardware (GPU NVIDIA RTX 4060, rastreamento de kernel CUDA em nível de camada) indicam que a aceleração Winograd depende de convoluções densas ($\text{groups}=1$), não apenas do tamanho do kernel, e que compete com *tensor cores* em lotes maiores. Os resultados sugerem que compensação estrutural leve — e não kernels maiores — é uma via eficiente para recuperar acurácia em arquiteturas compatíveis com Winograd neste protocolo, e que mecanismos de custo zero (um único atalho residual) podem aproximar-se de arquiteturas híbridas mais elaboradas.

Index Terms—Winograd, convolução, quantização, redes neurais convolucionais, kernel bottleneck, módulo Fire, atalho residual, INT8

I. INTRODUÇÃO

O algoritmo de convolução de Winograd [2] reduz o número de multiplicações necessárias para convoluções de kernel pequeno, sendo a base de aceleradores de inferência amplamente usados em hardware embarcado. Sua vantagem, porém, desaparece rapidamente conforme o kernel cresce: o fator de redução de multiplicações frente à convolução direta satura numa constante em vez de crescer indefinidamente, e as matrizes de transformação tornam-se numericamente

mal-condicionadas para kernels grandes [3], tornando kernels grandes (5×5 , 11×11) pouco atrativos nesses aceleradores.

Isso cria uma tensão direta com arquiteturas clássicas de visão computacional. A AlexNet [1], por exemplo, depende de kernels 11×11 e 5×5 em suas primeiras camadas para capturar contexto espacial amplo. Restringir ingenuamente esses kernels a 2×2 ou 3×3 — sem qualquer outra mudança arquitetural — reduz potencialmente a capacidade do modelo, pois cada camada enxerga uma vizinhança muito menor da imagem.

Este projeto investiga se essa perda de acurácia pode ser recuperada por meio de mecanismos de *compensação estrutural* que mantêm todos os kernels no regime Winograd-amigável ($\leq 3\times 3$), em vez de simplesmente devolver kernels grandes ao modelo. A hipótese central é que a restrição de tamanho de kernel, ainda que estruturalmente limitante, pode ser compensada por reorganizações arquiteturais de baixo custo — blocos *bottleneck*, módulos *Fire*, atalhos residuais — que redistribuem o poder representacional sem reintroduzir kernels grandes. Este relatório apresenta os resultados dessa investigação para dois mecanismos de compensação: blocos *bottleneck* no estilo ResNet [5] (redução de canais $1\times 1 \rightarrow$ convolução $3\times 3 \rightarrow$ expansão 1×1) e módulos *Fire* no estilo SqueezeNet [4] (*squeeze* $1\times 1 \rightarrow$ *expand* $1\times 1/3\times 3$), aplicados a uma AlexNet com kernels restritos a 3×3 . Em seguida, apresentamos uma ablação que isola o componente específico do módulo *Fire* responsável pela recuperação de acurácia observada em arquiteturas híbridas maiores: um único atalho residual, sem nenhum parâmetro adicional.

II. METODOLOGIA

A. Dados e configuração experimental

Todos os modelos foram avaliados no Tiny ImageNet-200 [9] (imagens 64×64 RGB, 200 classes, *split* 90/10 determinístico) sob o mesmo pipeline de três estágios: (i) treino FP32 — do zero para a grande maioria das variantes, exceto a baseline AlexNet irrestrita e os baselines externos ResNet18 [5]/MobileNetV2 [6] (Seção III-A), que partem de pesos pré-treinados em ImageNet-1K e são apenas ajustados (*fine-tuned*) para as 200 classes do Tiny ImageNet; (ii) *Quantization-Aware Training* (QAT), inicializado a partir do melhor checkpoint FP32, com fusão Conv-BN-ReLU e *fake quantization* nos

módulos suportados [7] — as arquiteturas com atalho residual usam `nn.quantized.FloatFunctional` no lugar do operador `+` para o *add*, requisito do PyTorch para que a soma também seja quantizada corretamente; (iii) conversão para INT8 (*backend* `fbgemm`, inferência em CPU). Reportamos acurácia top-1 tanto para o modelo FP32 quanto para o modelo INT8 final, e a diferença entre ambos (*QAT drop*) como medida de robustez à quantização.

B. Arquiteturas comparadas

Sete variantes permitem isolar o efeito da restrição de kernel, o efeito do *head* GAP, o efeito de diferentes mecanismos de compensação, e o efeito de cada componente dentro de uma arquitetura híbrida. Todas são treinadas do zero sob o mesmo protocolo (Seção II-A), com exceção da baseline irrestrita, que é pré-treinada (ver abaixo):

- **AlexNet (irrestrita)** — arquitetura AlexNet padrão, kernels de até 11×11 , *pré-treinada em ImageNet-1K* e ajustada (*fine-tuned*) para 200 classes, usada como referência interna do experimento. Diferentemente de todas as demais variantes abaixo — treinadas do zero — essa baseline parte de pesos pré-treinados; comparações diretas de acurácia com ela confundem o efeito da restrição de kernel com o efeito do pré-treino (ver Seção IV).
- **AlexNet3x3-FC** — mesma arquitetura irrestrita, mas com todos os kernels convolucionais restritos a 3×3 e treinada do zero, mantendo a *head* totalmente conectada original. Serve de controle para isolar o efeito da restrição de kernel isoladamente do *head* GAP (usado apenas no próximo item) e do pré-treino.
- **AlexNet3x3-GAP** — mesma arquitetura, todos os kernels convolucionais restritos a 3×3 , com *head* de *global average pooling* (GAP) [16] no lugar de camadas totalmente conectadas.
- **AlexNetBottleneck** — kernels igualmente restritos a 3×3 , mas cada estágio é substituído por um bloco *bottleneck* ($1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$, razão de redução $4 \times$) seguido de GAP.
- **AlexNetFire** — kernels restritos a 3×3 , cada estágio substituído por um módulo *Fire* [4] (*squeeze* $1 \times 1 \rightarrow \text{expand } 1 \times 1 + 3 \times 3$, concatenados) seguido de GAP.
- **AlexNetFinalFireResidual** — arquitetura híbrida final que combina o módulo *Fire* acima com um novo *stem* 3×3 *stride*-2 e atalhos residuais envolvendo cada estágio *Fire*.
- **AlexNetFireBypass** — arquitetura de ablação que parte do AlexNetFire original (mesmo *stem*, mesmos módulos *Fire*) e adiciona apenas um atalho residual por identidade em cada estágio, sem nenhum parâmetro extra em relação ao AlexNetFire base. Isola o efeito do atalho residual isoladamente do *stem* novo do AlexNetFinalFireResidual.

O bloco *bottleneck* e o módulo *Fire* preservam o campo receptivo efetivo da convolução 3×3 central, mas usam convoluções 1×1 para comprimir e depois expandir (ou

concatenar) canais, aumentando a capacidade representacional por parâmetro sem introduzir nenhum kernel maior que 3×3 — mantendo a arquitetura inteiramente compatível com aceleração Winograd. O atalho residual por identidade usado no AlexNetFireBypass não introduz nenhuma convolução adicional, preservando trivialmente essa compatibilidade com Winograd.

C. Perfilamento de hardware

As medições de latência (Contribuição 3) foram feitas em uma única GPU NVIDIA RTX 4060 Laptop, em uma única sessão de coleta, cronometrando camadas *Conv2d* isoladas com `torch.cuda.synchronize` antes e depois de 200 iterações cronometradas (50 iterações de *warmup* descartadas). O algoritmo de convolução (Winograd, direto, ou GEMM via *tensor cores* TF32) é escolhido internamente pelo cuDNN a cada configuração — não é forçado pelo experimento — e identificado *a posteriori* por rastreamento do nome do *kernel* CUDA executado (`torch.profiler`). Por ser uma única sessão em uma laptop GPU com limite de potência, o *clock* sustentado observado varia entre sessões (deriva de até $2 \times$ em medições de controle no mesmo dia), então diferenças pequenas de latência devem ser lidas com essa incerteza em mente; ver limitações na Seção IV.

III. RESULTADOS

A. Contribuição 1: Custo de Restrição de Kernel e Mecanismos de Compensação

Os três *baselines* externos da Figura 1 situam essa restrição num contexto mais amplo, fora do escopo Winograd-amigável ($\leq 3 \times 3$) deste estudo: MobileNetV2 pré-treinada atinge 58,0% de acurácia FP32 (28,75 MB, a maior do gráfico), ResNet18 pré-treinada 53,9% (129,21 MB), e VGG-Style — treinada do zero, sem pré-treino — 51,8% (27,58 MB). Do lado da restrição ingênua, o par completo citado na legenda é AlexNet3x3-FC (35,79%, discutida abaixo) e AlexNet2x2-FC (30,53%, treinada do zero) — kernel 2×2 sozinho, sem compensação estrutural, fica abaixo até da baseline AlexNet pré-treinada de kernel irrestrito.

A Tabela I resume o custo de restringir kernels a 3×3 e a efetividade de dois mecanismos de compensação: blocos *bottleneck* e módulos *Fire*. Params e MACs medem eficiência de armazenamento e de computação separadamente — como a Contribuição 3 mostra, eles nem sempre concordam sobre qual arquitetura é “mais eficiente”. AlexNet3x3-FC isola o efeito da restrição de kernel isoladamente do *head* GAP: mantém a *head* totalmente conectada da baseline, mas restringe kernels a 3×3 e treina do zero (diferente da baseline irrestrita, pré-treinada). Note que, apesar do kernel menor, AlexNet3x3-FC tem mais MACs que a baseline (222,3M vs. 94,9M): o *stem* 3×3 usa *stride* 2 em vez do *stride* 4 do *stem* 11×11 original, então os mapas de ativação permanecem maiores por mais camadas — um kernel menor por aplicação, mas aplicado sobre uma área espacial bem maior no total.

Três resultados se destacam, e o primeiro contraria a hipótese inicial do projeto. Isolando a restrição de kernel da

Tabela I
CUSTO DE RESTRIÇÃO DE KERNEL (3×3) E MECANISMOS DE COMPENSAÇÃO

Modelo	Params (M)	MACs (M)	Top-1 FP32 (%)	Top-1 INT8 (%)	Δ QAT (p.p.)
AlexNet (irrestrita, pré-treinada)	57,82	94,9	32,88	31,90	-0,98
AlexNet3x3-FC (do zero)	57,61	222,3	35,79	36,19	+0,40
AlexNet3x3-GAP	2,30	167,0	40,32	37,02	-3,29
AlexNetBottleneck	0,39	39,5	44,62	44,54	-0,08
AlexNetFire	0,52	177,7	43,98	44,30	+0,33




Figura 1. Acurácia FP32 (top-1) por arquitetura, contrastando *baselines* externos de kernel irrestrito (MobileNetV2, ResNet18, VGG-Style), restrição ingênua (AlexNet 3×3 e 2×2), tentativas exploratórias de compensação (Mixed, Residual puro — não detalhadas individualmente neste relatório; SmallKernel é retomado com números na Contribuição 5) e a arquitetura híbrida final (Fire-Residual).

troca de *head* e do pré-treino (AlexNet 3×3 -FC vs. baseline irrestrita, ambas com *head* totalmente conectada), restringir kernels a 3×3 *sozinho* não custa acurácia neste protocolo — ao contrário, *ganha* 2,9 p.p. (32,88%→35,79%). Uma explicação plausível é que a *head* totalmente conectada de 57M parâmetros da baseline overfita mais facilmente num dataset de imagens 64×64 do que a mesma arquitetura treinada do zero com kernels restritos; isso não isola de forma limpa “custo da restrição de kernel” de “efeito do pré-treino ImageNet → Tiny ImageNet”, já que só a baseline é pré-treinada, então o resultado é sugestivo, não conclusivo. Segundo, trocar essa mesma *head* para GAP (AlexNet 3×3 -GAP) soma mais 4,5 p.p. (35,79%→40,32%) com 25× menos parâmetros —

a redução drástica de parâmetros (57M → poucos milhares) do *head* GAP é o efeito estrutural mais bem isolado desta tabela, consistente com redução de *overfitting* dada a dimensão reduzida do dataset (64×64 , 200 classes). Terceiro, adicionar o bloco *bottleneck* sobre essa mesma restrição de kernel recupera mais 4,3 pontos percentuais de acurácia com 6× menos parâmetros que a variante GAP simples, e praticamente elimina a perda de acurácia sob quantização INT8. O módulo *Fire* oferece um mecanismo alternativo de compensação: com apenas 0,52M parâmetros, alcança 43,98% de acurácia em FP32, mantendo um *ganho* sob quantização (INT8 44,30%, +0,33 p.p.) — propriedade rara neste estudo, compatível com a hipótese de que a compressão interna via *squeeze-expand* pode facilitar a calibração de quantização (e.g., ativações mais regulares), embora o mecanismo exato permaneça especulativo. Em MACs, porém, esse ganho de parâmetros não se traduz em menos computação: o Fire usa 177,7M MACs, mais que a própria AlexNet 3×3 -GAP (167,0M) e 4,5× mais que o *Bottleneck* (39,5M) — os dois mecanismos otimizam eficiência de armazenamento por caminhos bem diferentes, e apenas o *Bottleneck* também reduz computação.

B. Contribuição 2: Sinergia de Arquiteturas Híbridas

Investigamos combinações de mecanismos de compensação para maximizar a sinergia entre mecanismos estruturais. A Tabela II compara cinco combinações de *bottleneck*, *Fire*, atalhos residuais e convoluções *depthwise*.

A combinação Fire + Residual emerge como mais efetiva, ganhando 5,81 p.p. sobre o Fire de base (43,98% → 49,79%) — um efeito não linear que sugere sinergia entre compressão canais (*squeeze-expand*) e conexões residuais. Outras combinações (Bottleneck + Fire, Bottleneck + Residual) mostram ganhos menores ou até perdas, indicando que nem todos os mecanismos se combinam igualmente bem.

C. Contribuição 3: Validação em Hardware da Aceleração Winograd

Investigamos se as arquiteturas do projeto realmente acionam aceleração Winograd em GPU, e sob quais condições. Duas fontes de evidência, de força bem diferente, são usadas: (i) rastreamento direto do nome do *kernel* CUDA executado pelo cuDNN — a evidência mais forte, pois identifica o algoritmo em vez de inferi-lo; e (ii) o *scaling* de latência com o tamanho do kernel, testado estatisticamente — uma evidência indireta e, como mostrado abaixo, inconclusiva no regime que mais importa.

Tabela II
ABLAÇÃO DE ARQUITETURAS HÍBRIDAS: SINERGIA ENTRE MECANISMOS DE COMPENSAÇÃO

Arquitetura	Params (M)	Top-1 FP32 (%)	Top-1 INT8 (%)	Δ QAT (p.p.)
AlexNetFire (base)	0,52	43,98	44,30	+0,33
Fire + Residual (AlexNetFinalFireResidual)	0,70	49,79	49,20	-0,59
Bottleneck + Fire (AlexNetFinalBottleneckFire)	0,51	42,29	44,00	+1,71
Bottleneck + Residual (AlexNetFinalBottleneckResidual)	0,57	45,10	45,98	+0,88
Depthwise + Fire (AlexNetFinalDepthwiseFire)	0,47	43,46	42,79	-0,67

O rastreamento de *kernel* indica que o cuDNN seleciona um algoritmo identificado como Winograd especificamente para convoluções densas ($\text{groups}=1$) com $\text{kernel } 3 \times 3$, nos *batches* 1 e 8 — mas não para convoluções *depthwise*, em nenhum tamanho de kernel (2 a 11) ou *batch* testado nesta GPU e backend. Esse é o resultado mais direto desta seção.

O teste de *scaling* teórico é mais fraco. A complexidade de Winograd não é assintoticamente menor que a da convolução direta: para um *tile* de saída fixo de $m \times m$ elementos, o número de multiplicações de Winograd, $(m+k-1)^2$, e o da convolução direta, m^2k^2 , crescem ambos como $\Theta(k^2)$ com o tamanho do $\text{kernel } k$ [2] — por exemplo, $F(2 \times 2, 3 \times 3)$ usa 16 multiplicações contra 36 da convolução direta ($2, 25 \times$), e $F(4 \times 4, 3 \times 3)$ usa 36 contra 144 ($4 \times$) [2]; essa vantagem converge para um fator constante ($m^2 \times$) quando $k \rightarrow \infty$, em vez de crescer indefinidamente. Na prática, Winograd raramente é usado além de $k = 3$ (ocasionalmente $k = 5$) não por essa escala assintótica, mas porque as matrizes de transformação ficam numericamente mal-condicionadas para k grande [3]. A Figura 2 mostra a latência por FLOP medida para $k \in \{2, 3, 5, 7, 9, 11\}$. Um teste de Wilcoxon pareado [10] — não-paramétrico, adequado para comparar duas condições medidas nas mesmas configurações sem assumir normalidade dos dados — (latência por FLOP, $k=3$ vs. $k=5$, denso) no regime *compute-bound* ($\text{batch} = 64$, a evidência primária — ver painel central da figura) é **estatisticamente significativo, mas na direção oposta à esperada**: $p = 0,023$, $n = 8$, e a mediana do custo por FLOP em $k=3$ não é menor que em $k=5$ — o teste rejeita a hipótese nula de nenhuma diferença sistemática, mas não corrobora a hipótese de que Winograd ($k=3$) é mais eficiente por FLOP nesse regime. No regime *overhead-bound* ($\text{batch} = 1/8$, secundário — onde a GPU fica ociosa e o tempo é dominado por setup de kernel e sincronização) há uma tendência favorável (mediana $\sim 7\%$ menor em $k=3$), mas sem significância estatística ($p = 0,82$, $n = 16$). Neste regime, o overhead mascara ganhos de redução de FLOP, então a vantagem teórica de Winograd não se manifesta. Consistente com isso, o próprio rastreamento de *kernel* mostra que, em $\text{batch} = 64$ (regime *compute-bound*, onde a GPU está saturada e o tempo é dominado por cálculos reais — exatamente onde Winograd deveria brilhar), o cuDNN troca Winograd por um *kernel* TF32 de *tensor core* mesmo em $k=3$ — ou seja, no regime onde a redução de FLOP teria mais efeito, *tensor cores* ganham a competição e nem sempre há Winograd para medir. A leitura mais defensável não

é que Winograd não ajuda, mas que *tensor cores* competem com a vantagem de Winograd justamente no regime *compute-bound*, onde uma redução de multiplicações teria mais efeito — achado interessante para o acelerador FPGA que motiva este projeto (sem *tensor cores*), mas que este experimento em GPU não pode confirmar diretamente.

Para convoluções *depthwise*, o quadro é mais consistente: nenhuma evidência de Winograd foi encontrada em nenhum regime. No nível de camada, o mesmo teste de Wilcoxon [10] (*compute-bound*, denso vs. $\text{groups}=\text{in_ch}$) rejeita sinal Winograd para *depthwise* ($p = 0,0078$, $n = 8$). No nível de modelo completo, *alexnet_depthwise_sep* e *mobilenetv2* (85,0 e 24,9 GFLOP/s, mediana 54,9) ficam bem abaixo de quatro modelos densos comparáveis (*alexnet_bottleneck*, *alexnet_final_bottleneck_residual*, *alexnet_final_fire_residual*, *vgg_style*; mediana 112,5 GFLOP/s) — comparação de apenas $n = 2$ modelos *depthwise*, exploratória. O mais correto a afirmar é que, *nesta GPU e neste backend (cuDNN)*, convoluções *depthwise* não acionam um *kernel* Winograd, não que o algoritmo seja matematicamente incompatível com elas — a literatura descreve variantes de Winograd por canal para convoluções *depthwise* [13]; o que este experimento demonstra é que o cuDNN, nesta configuração, não as implementa.

Mapeamos também a fronteira de Pareto entre acurácia e latência para o conjunto completo de arquiteturas (Figura 3).

Quatro de cinco arquiteturas com convolução 3×3 densa (*AlexNetBottleneck*, *AlexNetFire*, *AlexNetFinalBottleneckResidual*, *AlexNetFinalFireResidual*) superam o baseline (*AlexNetTV*, irrestrito) na razão acurácia/latência. A latência em FP32 também é um preditor razoável do *ranking* de latência em INT8, mas só para convoluções densas (correlação de Spearman $\rho = 0,99$, $n = 24$); para *depthwise* a correlação é sensivelmente mais fraca ($\rho = 0,72$, $n = 24$) — o *backend* INT8 (*fbgemm*) tem *kernels* otimizados só para $3 \times 3/5 \times 5$ em convoluções agrupadas [8] e cai para um caminho genérico muito mais lento acima disso, o que quebra a correspondência FP32→INT8 nesse subconjunto.

Por fim, avaliamos a competição com *tensor cores* entre tamanhos de *batch*, no mesmo experimento acima: em $\text{batch}=1$ e 8 o cuDNN prefere Winograd em $k=3$; em $\text{batch}=64$ prefere um *kernel* TF32 de *tensor core* mesmo em $k=3$.

RTX 4060 Laptop (local): layer latency per FLOP vs. kernel size (dense/groups=1, res=64)




Figura 2. Latência por FLOP vs. tamanho de kernel (RTX 4060). O *scaling* sub-linear esperado de Winograd aparece de forma inconsistente entre regimes — ver texto para o teste estatístico e sua limitação no regime *compute-bound* (*batch*=64, painel central).

Accuracy vs. latency: Pareto frontier & baseline reference
(fp32 = GPU inference, int8 = CPU inference; per-precision deployment target)




Figura 3. Fronteira de Pareto acurácia $\times$ latência (FP32 e INT8, RTX 4060, *batch*=1). Cor indica o mesmo agrupamento da Figura 1 (*baselines* irrestritos, restrição ingênua, tentativas de compensação, arquitetura híbrida final); forma indica precisão (círculo = FP32, quadrado = INT8). Modelos com convolução 3×3 densa (*bottleneck*, Fire) atingem latência competitiva com trade-off de acurácia face ao baseline irrestrito; modelos *depthwise* não recebem aceleração Winograd apesar do kernel pequeno.

Isso é uma limitação da GPU como plataforma de validação, não uma medição do princípio em si: o acelerador FPGA

que motiva este projeto não possui *tensor cores*, então essa competição específica não deveria ocorrer nele — mas essa é

uma expectativa baseada na ausência de *tensor cores* no design do FPGA, não algo medido neste trabalho.

D. Contribuição 4: Bypass Residual de Custo Zero

Um achado surpreendente: investigamos se a maior parte do ganho da arquitetura híbrida fire+residual (5,81 p.p. ganho sobre Fire de base) provém especificamente do atalho residual. Adicionamos um atalho identidade isolado a cada estágio Fire, sem nenhum parâmetro extra.

A Tabela III compara o Fire de base com essa ablação por atalho isolado (FireBypass) e a arquitetura híbrida completa.

O AlexNetFireBypass adiciona um único atalho residual por identidade a cada estágio *Fire*, sem nenhum parâmetro extra (0,52M em ambos os casos). Apesar dessa simplicidade, fecha 87% do ganho FP32 da arquitetura híbrida completa (5,05 de 5,81 p.p.) e a *supera* no regime INT8 (49,86% vs. 49,20%), mantendo ganho sob quantização (+0,84 p.p. vs. -0,59 p.p. do híbrido completo). Esse resultado isolado sugere que o atalho residual — não o novo *stem* da arquitetura híbrida — é o componente responsável pela maior parte do ganho de acurácia, e que pode ser adicionado a *custo estrutural zero*. Um adendo importante: o AlexNetFireBypass foi treinado com um orçamento de épocas maior que o restante do estudo (152 épocas efetivas, contra 77 do AlexNetFinalFireResidual — Tabela VI no apêndice), por ter sido executado no cluster PCAD da UFRGS sob um orçamento de época maior que o disponível localmente; parte do ganho de acurácia relatado aqui pode portanto também refletir esse treino mais longo, não apenas o atalho residual isoladamente. A Figura 4 situa esse resultado no conjunto completo de modelos do estudo.

A Figura 4 ordena todos os modelos segundo acurácia versus tamanho de modelo em disco, complementando a visão latência-cêntrica da Figura 3. Quatro achados se destacam: (i) AlexNetBottleneck e AlexNetFire ocupam a fronteira de Pareto acurácia-tamanho, enquanto a restrição ingênua (AlexNet3x3-GAP) fica abaixo, sugerindo que compensação estrutural recupera acurácia sem inchar o modelo; (ii) as trajetórias FP32→INT8 (linhas cinza) revelam robustez de quantização: modelos de compensação descem pouco (Bottleneck, Fire), enquanto MobileNetV2 e restrição ingênua descem bruscamente, reforçando que estrutura importa para INT8, não só FP32; (iii) Bottleneck usa menos parâmetros que Fire (0,39M vs. 0,52M), mas Fire usa mais MACs (177,7M vs. 39,5M) — um trade-off de dimensões ortogonais: tamanho em disco é dominado por parâmetros, latência por MACs, e os dois mecanismos otimizam diferentes custos; (iv) MobileNetV2 e ResNet18 (sem ponto INT8 aqui) não ganham na dimensão tamanho apesar de melhor acurácia FP32, pois são muito maiores — uma restrição que desaparece num acelerador com foco em throughput em vez de latência pura.

E. Contribuição 5: Robustez de Quantização e Comparação de Métodos de Compressão

Além de acurácia e latência, investigamos como diferentes mecanismos de compensação afetam a robustez sob quantização INT8 e compressão adicional.

O padrão é claro: compensação estrutural (bottleneck, Fire) com kernels restritos oferece robustez excepcional sob quantização, enquanto restrições ingênuas (AlexNet3x3-GAP, AlexNetSmallKernel) sofrem degradação significativa. AlexNetSmallKernel é a variante mais enxuta do estudo: mesmo *backbone* totalmente 3×3 do AlexNet3x3-GAP, mas com canais bem mais estreitos (64→128→256→256) e, como o AlexNet3x3-GAP, sem *BatchNorm*. É o modelo mais compacto do estudo em número de parâmetros dentre as variantes de kernel restrito sem compensação, mas também o que mais sofre com a quantização: sem BN após cada convolução e com canais estreitos, resta pouca margem de ativação para absorver o ruído de quantização — ao contrário de AlexNetBottleneck/AlexNetFire, que têm BN após toda convolução (Seção III-A). A Tabela IV agrupa modelos por família e mostra a queda de acurácia FP32→INT8 (*drop*) para cada uma.

Com relação a métodos adicionais de compressão além de INT8 padrão, testamos precisão mista INT4/INT8 e investigamos *weight-sharing* pós-hoc. A precisão mista atribui bits por camada por sensibilidade: cada camada quantizável tem seus pesos fake-quantizados isoladamente para INT4 (por canal de saída), mede-se o EQM dos *logits* resultantes contra o *baseline* FP32 num único *batch* de calibração, e as camadas são ranqueadas por essa sensibilidade — as 30% mais sensíveis permanecem em INT8, o restante vai para INT4, seguido de *fine-tuning*. A Figura 5 mostra que métodos sub-INT4 mais agressivos (ternary, int2, binary, todos QAT) sofrem quedas de 22 a 37 p.p., enquanto INT4 QAT permanece viável (<2 p.p. drop) para famílias de compensação, e essa precisão mista INT4/INT8 oferece a melhor taxa de compressão entre os métodos com retreino (7,05×) mantendo acurácia média de 44,52%, um ganho médio de 0,19 p.p. sobre o FP32 dos mesmos 3 modelos.

Três ressalvas limitam a aplicabilidade imediata desses resultados: (i) INT4 PTQ sem retreino colapsa (25,3%) porque a calibração de quantização com um único *batch* não captura a distribuição real de ativações — o retreino (QAT) é crítico, triplicando a acurácia; (ii) INT4 em hardware real permanece fora do escopo: *fbgemm* (backend INT8 deste estudo) prioriza INT8, com suporte INT4 limitado; FPGA/aceleradores móveis suportam-no de forma inconsistente — esta medição é teórica; (iii) a compatibilidade com aceleração Winograd não é verificada — restrições de INT4 podem exigir reformatação de peso ou descontinuar a densidade que Winograd requer.

1) *Nota adicional: viabilidade de poda estruturada*: Como verificação adicional e preliminar (não um resultado central deste relatório), testamos poda estruturada de canais inteiros (não pesos individuais) no AlexNetBottleneck, razão

Tabela III
ABLAÇÃO DO ATALHO RESIDUAL: ISOLANDO O COMPONENTE DECISIVO DA ARQUITETURA HÍBRIDA

Arquitetura	Params (M)	Top-1 FP32 (%)	Top-1 INT8 (%)	Ganho Vs. Fire (p.p.)
AlexNetFire (base)	0,52	43,98	44,30	—
AlexNetFireBypass	0,52	49,03	49,86	+5,05 FP32
AlexNetFinalFireResidual (híbrida completa)	0,70	49,79	49,20	+5,81 FP32




Figura 4. Acurácia top-1 vs. tamanho (MB, escala log) para todos os modelos discutidos neste relatório, FP32 e INT8. Cor indica o mesmo agrupamento da Figura 1 (*baselines* irrestritos, restrição ingênua, tentativas de compensação, arquitetura híbrida final); forma indica precisão (círculo = FP32, quadrado = INT8), e linhas cinza conectam o par FP32/INT8 de cada modelo. As linhas tracejada e pontilhada são as fronteiras de Pareto acurácia-tamanho para FP32 e INT8, respectivamente. MobileNetV2 e ResNet18 não têm ponto INT8 porque QAT foi pulado para ambos (*residual adds* sem `FloatFunctional`, Seção III-A). AlexNet (irrestrita) usa a mesma execução de 79 épocas padronizada na Tabela I.

Tabela IV
ROBUSTEZ DE QUANTIZAÇÃO: QUEDA FP32→INT8 POR FAMÍLIA DE MODELO

Família	Modelo	Top-1 FP32	Top-1 INT8	Drop (p.p.)
Compensação com 3×3	AlexNetBottleneck	44,62%	44,54%	−0,08
	AlexNetFire	43,98%	44,30%	+0,33
Restrição ingênua	AlexNet3x3-GAP	40,32%	37,02%	−3,29
	AlexNetSmallKernel	45,84%	36,16%	−9,67
Baseline irrestrito	AlexNetTV	32,88%	31,90%	−0,98

0,4, seleção por norma L1 [11]: 385.000→207.399 parâmetros (−46,1%; 53,9% dos parâmetros originais retidos), mantendo toda convolução remanescente com `groups=1` (elegível à aceleração Winograd por construção). Sem *fine-tuning* após a poda a acurácia colapsa (top-1 0,50%), como esperado — este é apenas um teste de que a poda preserva `groups=1`, não um resultado de acurácia competitivo. A literatura de poda estruturada por norma L1 mostra que *fine-tuning* pós-poda

recupera acurácia próxima à do modelo original [11], o que motiva tratar essa recuperação como trabalho futuro plausível, não apenas como esperança.

2) *Nota adicional: headroom de compressão via weight-sharing*: Em paralelo à poda, investigamos o potencial de compressão adicional além de INT8 puro, medindo quanto espaço ainda existe entre a entropia real dos pesos e a largura de bits nominal. Para o AlexNetFire, os pesos INT8




Figura 5. Acurácia top-1 média por método de compressão além de INT8, com taxa de compressão (tamanho do checkpoint FP32 dividido pelo tamanho do checkpoint comprimido) e número de modelos (n) entre parênteses. INT4 PTQ (sem retreino) colapsa para 25,3%; retreinar sob o mesmo INT4 (QAT) recupera para 43,3% — o retreino, não a largura de bits em si, é o que preserva a acurácia. Precisão mista INT4/INT8 (QAT) supera até o INT4 QAT uniforme com taxa de compressão comparável. Métodos sub-INT4 mais agressivos (ternary, int2, binary, todos QAT) degradam progressivamente.

reais ocupam apenas 7,19 bits/peso de entropia de Shannon (contra 8,00 nominais), sugerindo margem para métodos de quantização com perda como *weight-sharing*. Aplicamos *k-means* clustering — o passo de codebook do Deep Compression [12] — em 16/32/64 *clusters* (correspondendo a 4/5/6 bits nominais), e observamos que o arquivo comprimido com gzip em disco fica 1,18× menor que INT8 puro, chegando a ~2,2× de *headroom* adicional (só pesos) em 16 *clusters*. É uma medição teórica, não uma avaliação de acurácia real pós-clustering nem uma mudança efetiva no formato de checkpoint — apenas um sinal de que uma pipeline real de *weight-sharing* vale a pena construir (ver Trabalhos Futuros).

F. Síntese das cinco contribuições

Os cinco pilares deste trabalho conectam-se em uma narrativa coerente:

- 1) *Custo da Restrição de Kernel (Contribuição 1)*: Neste protocolo, restringir kernels a 3×3 isoladamente não custou acurácia (ganhou 2,9 p.p. de zero, contra a baseline pré-treinada) — o custo intuído na Seção I não se confirmou de forma limpa aqui; a troca de *head* para GAP foi a mudança com efeito isolado mais claro (+4,5 p.p.).
- 2) *Mecanismos de Compensação (Contribuição 1)*: Sobre a base restrita+GAP, blocos *bottleneck* e módulos *Fire* recuperam mais 3,7–4,3 p.p. com parâmetros drasticamente reduzidos (0,39–0,52M vs. 57,8M do baseline) e melhoram a robustez de quantização — mas não reduzem MACs na mesma proporção (Fire usa mais MACs que a própria variante GAP).
- 3) *Sinergia Híbrida (Contribuição 2)*: Fire + Residual não é apenas a soma de seus efeitos; oferece sinergia não-

linear (+5,81 p.p. acima do Fire de base). Nem todas as combinações de mecanismos sinergizam igualmente bem.

- 4) *Validação em Hardware (Contribuição 3)*: O rastreamento de *kernel* confirma que o cuDNN aciona Winograd para convoluções densas 3×3 em *batches* pequenos, e nunca para *depthwise*. O teste estatístico de latência, porém, é significativo na direção oposta à esperada no regime *compute-bound* — *tensor cores* parecem competir com a vantagem de Winograd justamente aí. Um acelerador FPGA sem *tensor cores* evitaria essa competição por construção, mas isso é uma expectativa de *design*, não algo medido neste trabalho.
- 5) *Atalho de Custo Zero (Contribuição 4)*: Um atalho residual isolado fecha 87% do ganho da arquitetura híbrida completa, sem parâmetros extras. Sugere que simplicidade estrutural pode ser mais poderosa que complexidade elaborada, ao menos para esta família de arquiteturas.

IV. DISCUSSÃO

Os modelos com compensação (*bottleneck*, *Fire*) mostram robustez excepcional sob quantização INT8 (−0,08 a +0,33 p.p.), enquanto a restrição ingênua sofre 3–10 p.p. de queda. Uma hipótese plausível é que as convoluções 1×1 do *bottleneck/squeeze* produzem ativações com distribuições mais regulares, facilitando a calibração de quantização; um teste direto dessa hipótese permanece trabalho futuro.

No plano de hardware, medições em RTX 4060 mostram que *tensor cores* competem com Winograd em *batches* grandes (≥ 64) — ver Contribuição 3 para o detalhamento e as ressalvas estatísticas dessa medição. Isso é uma limitação

da plataforma de validação, não algo demonstrado sobre o princípio em si: um acelerador FPGA sem *tensor cores* (motivação deste projeto) não sofreria essa competição *por construção*, mas essa é uma expectativa de *design*, não algo medido neste trabalho. Na mesma linha, MobileNetV2 e AlexNetDepthwiseSep, apesar de terem kernels pequenos, nunca acionam um *kernel* Winograd nesta GPU/backend (~51% menos GFLOP/s de mediana que modelos densos comparáveis) — o que sugere que arquiteturas eficientes para dispositivos móveis podem necessitar estratégias de otimização diferentes daquelas propostas aqui, sem que isso implique incompatibilidade matemática entre Winograd e convoluções *depthwise* em geral.

Limitações. (i) A comparação com a baseline irrestrita (Tabela I) mistura três fatores — tamanho de kernel, *head* FC/GAP e pré-treino ImageNet — que não são completamente separáveis com os controles deste estudo; AlexNet3x3-FC isola o primeiro dos dois últimos, mas nenhuma variante restrita é pré-treinada, então o efeito do pré-treino especificamente permanece confundido. (ii) O modelo `alexnet_tv` foi treinado de forma independente em dois momentos do projeto (79 e 67 épocas), com resultados diferentes, especialmente em INT8 (31,90% vs. 26,28%); este relatório padroniza na execução de 79 épocas (a mesma usada no perfilamento de hardware) em todas as tabelas, mas a diferença entre execuções é, em si, um indício de variância não desprezível entre treinos nominalmente idênticos. (iii) Toda a validação de hardware é de uma única GPU (RTX 4060 Laptop), em uma única sessão de coleta — sem repetição entre sessões, sem outra GPU, e sem qualquer medição em FPGA; a Contribuição 3 já discute como isso limita a leitura dos testes estatísticos de latência. (iv) Os testes estatísticos de hardware operam com n pequeno (8–24 configurações), o que limita seu poder — a evidência mais confiável desta seção é o rastreamento direto do nome do *kernel*, não os testes de latência. (v) Nenhum dos resultados de acurácia usa múltiplas sementes de treino; diferenças de poucos décimos de ponto percentual entre arquiteturas próximas não devem ser lidas como significativas.

V. CONCLUSÃO

Restringir kernels de CNNs a 3×3 para compatibilidade com aceleradores Winograd não se mostrou claramente custoso em acurácia neste protocolo, quando isolado de outras mudanças (Contribuição 1) — um resultado que contraria a expectativa inicial deste projeto. O que de fato eleva a acurácia acima da baseline pré-treinada é a combinação com um *head* GAP e mecanismos de compensação leves — blocos *bottleneck*, módulos *Fire*, ou atalhos residuais isolados — nenhum dos quais reintroduz $\text{kernel} > 3 \times 3$.

Com apenas 0,385M parâmetros (4,49 MB) e 39,5M MACs — menos de um quarto dos MACs do módulo *Fire* (177,7M), a menor contagem de computação entre os mecanismos de compensação testados — o AlexNetBottleneck atinge 44,62% de acurácia top-1 em FP32 e mantém 44,54% após INT8 (drop de apenas 0,08 p.p., o melhor do estudo). Entre os mecanismos de compensação estrutural testados, é o único

que reduz memória e computação simultaneamente frente à baseline restrita+GAP, relevante para um acelerador cujo custo escala principalmente com número de multiplicações. A ablação por atalho residual isolado revela que essa adição sozinha (zero parâmetros extras) captura aproximadamente 87% do ganho de uma arquitetura híbrida muito mais completa (5,05 de 5,81 p.p.) nesta família de arquiteturas, sugerindo que simplicidade estrutural pode aproximar-se de elaboração arquitetural complexa, ao menos aqui — com a ressalva crítica de que o AlexNetFireBypass usou um orçamento de épocas maior que o AlexNetFinalFireResidual (152 vs. 77 épocas, Apêndice B), então parte desse ganho pode refletir o treino mais longo, não apenas a mudança arquitetural.

A validação em hardware (RTX 4060, sessão única) mostra, por rastreamento direto do nome do *kernel* CUDA, que o cuDNN aciona um *kernel* Winograd para convoluções densas 3×3 em *batches* pequenos (1 e 8) — e nunca para convoluções *depthwise*, em nenhum tamanho de kernel testado. O teste estatístico de *scaling* de latência é, no entanto, significativo na direção oposta à esperada no regime *compute-bound* ($\text{batch}=64$), o mais relevante para um acelerador dedicado. Três achados limitam o escopo desta validação: (i) *tensor cores* parecem competir com a vantagem de Winograd justamente no regime *compute-bound*, tornando o ganho de latência inconsistente entre *batches*; (ii) convoluções *depthwise* nunca acionam Winograd nesta GPU/backend, ajudando a explicar por que MobileNetV2 não se beneficia como as arquiteturas densas; (iii) toda a medição vem de uma única GPU e uma única sessão de coleta. Um acelerador FPGA dedicado (motivação deste projeto) não possui *tensor cores* e, por construção, não sofreria a competição de (i) — mas essa é uma expectativa de *design*, não algo medido neste trabalho.

VI. TRABALHOS FUTUROS

A. Extensões em curto prazo

- 1) *Fine-tuning* pós-poda estruturada: Recuperar acurácia do AlexNetBottleneck podado (46,1% menos parâmetros, 0,385M $\rightarrow$ 0,207M), mantendo Winograd-elegibilidade via `groups=1` — literatura de poda por norma L1 [11] sugere que essa recuperação é factível.
- 2) *Weight-sharing* QAT-aware: Implementar pipeline real de *weight-sharing* [12] com retreino (contraste com a medição teórica de *headroom* já feita neste estudo), explorando os 7,19 bits/peso efetivos já usados por INT8.
- 3) Hardware profiling estendido: Medições de latência e potência em FPGA real ou acelerador dedicado, validando hipótese de tensor cores ser artefato de GPU.

B. Extensões em médio/longo prazo

1) *Transferência para Predição Densa: Detecção e Segmentação*: Investigar se mecanismos de compensação (*bottleneck*, *Fire*, *residual skip*) que funcionam bem em classificação também transferem para tarefas de predição densa. Treinar detectors SSD e segmenters FCN com backbones em PASCAL VOC 2012, usando as mesmas famílias de

modelos deste estudo. Resultados preliminares apontam para sim, mas a investigação ainda está sendo finalizada. Se confirmados, esses achados sugerem que compensação estrutural é um princípio fundamental transversal para otimização eficiente em CNNs, não apenas um artefato de classificação.

2) *Arquiteturas Eficientes Baseadas em Atenção (ViT Híbrido)*: Estender o framework de restrição de kernel para transformers. Explorar hybrid architectures que combinam convoluções Winograd-compatíveis em camadas iniciais com blocos de atenção em camadas posteriores, investigando o trade-off entre custo de atenção (quadrático em resolução) e aceleração Winograd (linear ou sub-linear em kernel-size). Resultados ainda não implementados.

Com essas extensões, esperamos consolidar o framework de kernel-restriction + compensation como um princípio de design prático para arquiteturas CNN eficientes em aceleradores Winograd, e validar se o princípio se estende além de classificação e além de CNNs puras.

AGRADECIMENTOS

Experimentos utilizaram recursos da infraestrutura PCAD (<http://pcad.inf.ufrgs.br>).

REFERÊNCIAS

- [1] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2012.
- [2] A. Lavin and S. Gray, "Fast algorithms for convolutional neural networks," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [3] B. Barabasz, A. Anderson, K. M. Soodhalter, and D. Gregg, "Error analysis and improving the accuracy of Winograd convolution for deep neural networks," *ACM Transactions on Mathematical Software*, vol. 46, no. 4, Art. 37, 2020.
- [4] F. N. Iandola, S. Han, M. W. Moskewicz, K. Ashraf, W. J. Dally, and K. Keutzer, "SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size," *arXiv preprint arXiv:1602.07360*, 2016.
- [5] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [6] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [7] B. Jacob *et al.*, "Quantization and training of neural networks for efficient integer-arithmetic-only inference," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [8] D. Khudia, J. Huang, P. Basu, S. Deng, H. Liu, J. Park, and M. Smelyanskiy, "FBGEMM: Enabling high-performance low-precision deep learning inference," *arXiv preprint arXiv:2101.05615*, 2021.
- [9] Y. Le and X. Yang, "Tiny ImageNet visual recognition challenge," Stanford CS231N Report, 2015.
- [10] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.
- [11] H. Li, A. Kadav, I. Durdanovic, H. Samet, and H. P. Graf, "Pruning filters for efficient ConvNets," in *International Conference on Learning Representations (ICLR)*, 2017.
- [12] S. Han, H. Mao, and W. J. Dally, "Deep compression: Compressing deep neural networks with pruning, trained quantization and Huffman coding," in *International Conference on Learning Representations (ICLR)*, 2016.
- [13] G. Li, R. Li, T. Li, T. Chen, M. Zhang, and H. Corporaal, "Algorithm-hardware co-design for accelerating depthwise separable CNNs," *ACM Transactions on Design Automation of Electronic Systems*, vol. 30, no. 2, 2025.
- [14] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations (ICLR)*, 2019.
- [15] E. D. Cubuk, B. Zoph, D. Mané, V. Vasudevan, and Q. V. Le, "AutoAugment: Learning augmentation strategies from data," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 113–123.
- [16] M. Lin, Q. Chen, and S. Yan, "Network in network," in *International Conference on Learning Representations (ICLR)*, 2014.

APPENDIX

A. Diagramas de Arquitetura

Para os quatro modelos que sustentam as Contribuições 1, 2 e 4 — os que ocupam a fronteira de Pareto acurácia/tamanho/quantização e são construídos inteiramente com convoluções $1\times 1/3\times 3$ (nenhum kernel $>3\times 3$) — as Figuras 6–9 mostram o diagrama de blocos por estágio, com canais de entrada/saída, contagem de parâmetros e o tipo de cada convolução interna (1×1 em cinza, 3×3 em verde), extraídos dos pesos treinados reais. Os diagramas são dispostos na horizontal (entrada à esquerda, *head* classificador à direita) para caber dois por página em largura total sem perder legibilidade. Os rótulos internos das figuras permanecem em inglês.

B. Dados de Treinamento

A Tabela V resume o protocolo de hiperparâmetros compartilhado por todos os modelos (Seção II-A), fixado nos arquivos `configs/training.yaml`, `configs/qat.yaml` e `configs/data.yaml` do repositório. O otimizador é AdamW [14] com *learning rate* decaído por *cosine annealing* ($T_{\max}$ = número de épocas do estágio); a taxa de aprendizado inicial, porém, é um hiperparâmetro *por modelo* (registrado junto à arquitetura, não um valor único global) — a Tabela VI lista o valor usado por cada um. No treino QAT, as estatísticas de *running mean/var* da BatchNorm são congeladas na época 3 e os observadores de quantização (que calibram escala e *zero-point*) são desativados na época 5 — prática recomendada por [7] para estabilizar a escala de quantização antes do restante do *fine-tuning* ajustar os pesos a ela.

A Tabela VI lista, por modelo, a taxa de aprendizado inicial (FP32), o número de épocas efetivamente treinadas até o melhor *checkpoint* (*early stopping* pode interromper antes do orçamento de 100 épocas) e o tempo de treino FP32 medido. O agrupamento por família replica o da Figura 1. O tempo total é o produto entre épocas e tempo médio por época — os modelos das famílias *baselines irrestritos* e *restrição ingênua*/AlexNetBottleneck/AlexNetFire foram treinados localmente (GPU única, RTX 4060 Laptop); as arquiteturas híbridas da Contribuição 2 (Bottleneck+Fire, Bottleneck+Residual, Depthwise+Fire) e da arquitetura híbrida final (AlexNetFinalFireResidual e AlexNetFireBypass) foram treinadas nos nós RTX 4090 do cluster PCAD (`configs/slurm/tupi_4090.yaml`); o AlexNetFireBypass, em particular, usou um orçamento de épocas maior que os demais modelos do estudo, daí as 152 épocas efetivas e 86,2 min de treino na tabela — bem acima do restante. Os tempos por época *não* são diretamente comparáveis entre si nem com as medições de latência da Contribuição 3, que usam exclusivamente a RTX 4060 Laptop (Seção II-C).




Figura 6. AlexNetBottleneck: bloco *reduce* $1 \times 1 \rightarrow \text{conv } 3 \times 3 \rightarrow \text{expand } 1 \times 1$ por estágio.




Figura 7. AlexNetFire: módulo *Fire* (*squeeze* $1 \times 1 \rightarrow \text{expand } 1 \times 1 / 3 \times 3$ concatenados) por estágio.




Figura 8. AlexNetFinalFireResidual: *stem* 3×3 *stride*-2 seguido de módulos *Fire* com atalho residual em cada estágio.




Figura 9. AlexNetFireBypass: AlexNetFire base com um atalho residual por identidade adicionado a cada estágio, sem nenhum parâmetro extra.

Tabela V
HIPERPARÂMETROS DE TREINAMENTO COMPARTILHADOS

Parâmetro	Valor
Otimizador	AdamW [14]
<i>Scheduler</i>	<i>Cosine annealing</i> (T_max = épocas)
Épocas (orçamento FP32)	100, <i>early stopping</i> paciência 5
Épocas (orçamento QAT)	20, <i>early stopping</i> paciência 5
<i>Weight decay</i> (FP32 / QAT)	5×10^{-4} / 5×10^{-4}
<i>Label smoothing</i>	0,1
<i>Batch size</i>	64
AMP (<i>mixed precision</i>)	Ligado (FP32) / desligado (QAT)
<i>Split</i> treino/validação	90/10 determinístico, seed 42
Aumento de dados (treino)	<i>RandomResizedCrop</i> (0,7–1,0), <i>flip</i> horizontal, <i>RandomRotation</i> (15°), <i>AutoAugment</i> (política ImageNet) [15]
Aumento de dados (validação)	<i>Resize</i> → <i>CenterCrop</i>
Normalização	Média/desvio-padrão do ImageNet
QAT: <i>freeze</i> BN / desativa <i>observers</i>	Época 3 / Época 5
INT8: <i>backend</i> / dispositivo	fbgemm / CPU

Tabela VI
TAXA DE APRENDIZADO, ÉPOCAS EFETIVAS E TEMPO DE TREINO FP32 POR MODELO

Família	Modelo	LR	Épocas	Tempo (min)
Baselines irrestritos	AlexNetTV (pré-trein.)	3×10^{-4}	79	63,2
	MobileNetV2 (pré-trein.)	1×10^{-4}	27	14,8
	ResNet18 (pré-trein.)	1×10^{-4}	15	7,1
	VGG-Style	1×10^{-3}	62	30,5
Restrição ingênua	AlexNet3x3-FC	3×10^{-4}	37	29,1
	AlexNet3x3-GAP	3×10^{-4}	43	16,3
	AlexNetSmallKernel	3×10^{-4}	62	24,5
Tentativas de compensação	AlexNetBottleneck	1×10^{-3}	76	29,6
	AlexNetFire	1×10^{-3}	41	21,7
	Bottleneck + Fire (AlexNetFinalBottleneckFire)	1×10^{-3}	40	13,9
	Bottleneck + Residual (AlexNetFinalBottleneckResidual)	1×10^{-3}	38	15,6
	Depthwise + Fire (AlexNetFinalDepthwiseFire)	1×10^{-3}	76	27,3
Arquitetura híbrida final	Fire + Residual (AlexNetFinalFireResidual)	1×10^{-3}	77	28,8
	AlexNetFireBypass	1×10^{-3}	152	86,2